

Inflacja w Szwecji

Sebastian Krzyślak


Justyna Zbiegień

Opis zmiennej

Wstęp

Opisywaną zmienną w niniejszym projekcie jest inflacja w Szwecji, a dane są pozyskiwane z ogólnodostępnych baz danych publikowanych przez Eurostat. Ta zmienna makroekonomiczna charakteryzuje się dużą stabilnością, zwłaszcza w porównaniu do CPI w innych krajach europejskich. Cel inflacyjny w Szwecji wynosi 2%, a obecnie wynosi ona ok. 1,4% (dane na Luty 2021). Obecnie inflacja w Szwecji wykazuje tendencję wzrostową, co było zdecydowanie zauważalne w styczniu tego roku, gdy to poziom inflacji osiągnął rekord 1,7% od grudnia 2019 roku. Jednym z czynników jest istniejąca pandemia Covid-19, jednak również istotnym czynnikiem okazały się być sektory transportu, rekreacji oraz kultury, w których to ceny wzrosły w relatywnie krótkim czasie. Poziom tej zmiennej przez ostatnie 10 lat kształtował się następująco:

Poziom inflacji w Szwecji (1997 – 2020)




Rysunek 1: Poziom inflacji w Szwecji (1997-2020)

Jak widać na powyższym obrazku (Rys.1) poziom inflacji w Szwecji charakteryzuje się stabilnością oraz dość niskim poziomem, w większości czasu poniżej 2%, gdzie wyjątkiem jest rok 2008, gdy nastąpiła wielka recesja.

Autokorelacja i test UR

W celu przeprowadzenia dalszych analiz sprawdzono, czy w danej zmiennej występuje zjawisko autokorelacji. Wyniki przedstawia poniższy wykres:

Inflacja w Szwecji (ACF)



Rysunek 2: Autokorelacja zmiennej

Jak widać na wykresie (Rys.2) autokorelacja występuje. Im mniejsze opóźnienie tym większy ma on wpływ na zmienną. Oznacza to, że wartości z okresu $t-1$ oraz $t-2$ mają większy wpływ na zmienną z okresu t niż wartości z okresu dalszego, np. $t-10$.

Przeprowadzono również badanie stacjonarności szeregu za pomocą testu ADF (Test Dickeya-Fullera), który ma następujące hipotezy:

H_0 : y_t jest niestacjonarny

H_1 : y_t jest stacjonarny

Test dla szeregu jak i opóźnień wyszedł z p-value poniżej 1% w obu przypadkach, oznacza to, że odrzucona jest hipoteza zerowa mówiąca o niestacjonarności szeregu. Jak napisano we wstępie inflacja w Szwecji jest dość stabilną zmienną, dlatego uzyskany wynik potwierdził przypuszczenia o stacjonarności. Dla porównania również przeprowadzono testy PP (Test Phillipsa-Perrona) oraz KPSS, które różnią się od podstawowego w tej analizie testu ADF. Test PP w przeciwieństwie do testu ADF jest nieparametryczny i dokonuje korektę testu o autokorelację oraz heteroskedastyczność, natomiast test KPSS jest zbliżony do testu PP z tym, że w nim hipoteza zerowa mówi o stacjonarności szeregu oraz jest bardziej wrażliwy na zaburzenia wynikające z rozmiaru próby. Wyniki dla tych testów przedstawia poniższy rysunek:

Testy pierwiastka jednostkowego	
Test	Decyzja
ADF	Odrzucenie H_0
PP	Odrzucenie H_0
KPSS	Odrzucenie H_0

Rysunek 3: Porównanie wyników testów na stacjonarność szeregu

Z tabeli (Rys.3) wynika, że test PP pokazał taki sam wynik, jak test ADF – stacjonarność szeregu, natomiast test KPSS wskazuje na niestacjonarność.

Model ARMA

Wstęp

Modele ARMA są bardzo częstymi modelami wybieranymi do zbudowania modelu predykcyjnego na podstawie szeregów czasowych. Składają się one z dwóch części: części autoregresyjnej (AR) oraz części średniej ruchomej (MA). Część MA można traktować jako rozwinięty składnik losowy, przez co podlega on zjawisku autokorelacji. Bez części autoregresyjnej można użyć podstawowego modelu MNK, jednak jeśli część autoregresyjna występuje, użycie metody MNK staje się niemożliwe, ponieważ model ARMA nie spełnia założeń KRML, a oszacowane estymatory MNK nie są zgodne. Szacowanie estymatorów modelu można przeprowadzić za pomocą nieliniowej MNK albo MNW.

Kryteria informacyjne

Ponieważ estymacja modelu ARMA MNK nie jest możliwa najczęściej się stosuje maksymalizację dokładnej funkcji wiarygodności. W ocenie wyestymowanych parametrów korzysta się z kryteriów informacyjnych, najczęściej są to AIC (Akaike'a), BIC (Schwarza) oraz Hannana-Quinna. Tutaj skorzystano z dwóch pierwszych kryteriów. Wyniki dla dokładnej funkcji wiarygodności w zależności od liczby szacowanych parametrów dla wybranych kryteriów informacyjnych prezentują się następująco:

AIC	ma0	ma1	ma2	ma3
ar0	724,18	477,42	338,67	295,98
ar1	195,83	196,98	198,12	198,26
ar2	196,59	194,65	198,43	196,72
ar3	198,38	199,25	181,44	183,41

Rysunek 4: Kryterium AIC

BIC	ma0	ma1	ma2	ma3
ar0	731,52	488,43	353,35	314,33
ar1	206,83	211,65	216,45	220,26
ar2	211,24	212,97	220,4	222,36
ar3	216,68	221,21	207,05	212,69

Rysunek 5: Kryterium BIC

Jak widać na powyższych rysunkach (Rys.4, Rys.5) według kryterium AIC wybrano model ARMA(3,2), a według kryterium BIC wybrano model ARMA(1,0). Do dalszych badań wybrano model ARMA(1,0), ponieważ posiada mniej parametrów, przez co jest mniej skomplikowany.

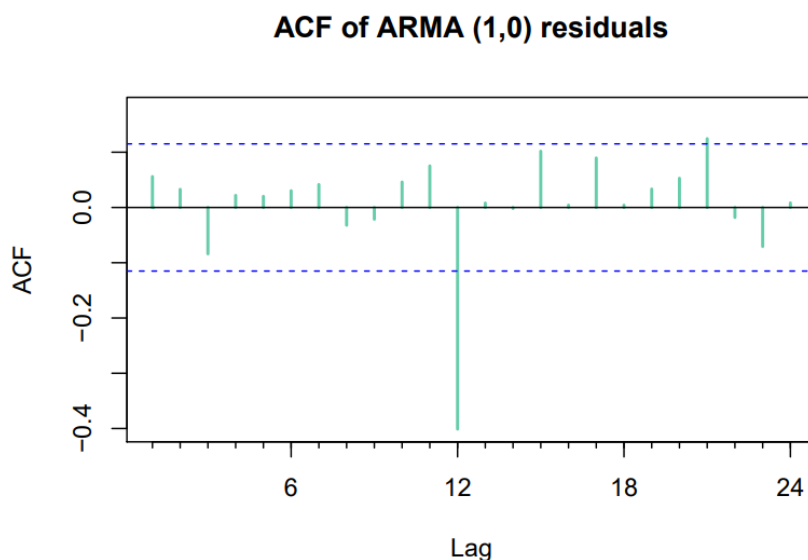
Szacowanie modelu ARMA (1,0) i pierwiastki charakterystyczne

Oszacowany model ma następującą postać:

$$Y_t = 0,915Y_{t-1} + 1,5$$

Jak łatwo zauważyć równanie ma tylko jeden pierwiastek charakterystyczny, co jest skutkiem stacjonarności szeregu oraz braku dużej zmienności wartości. Należy również zauważyć, że $\lambda = 0.915$, czyli $|\lambda| < 1$ co oznacza jednoznacznie, że szereg jest stacjonarny.

Dla tego modelu sprawdzono zjawisko autokorelacji (ACF) dla reszt części autoregresyjnej AR. Wyniki są następujące:

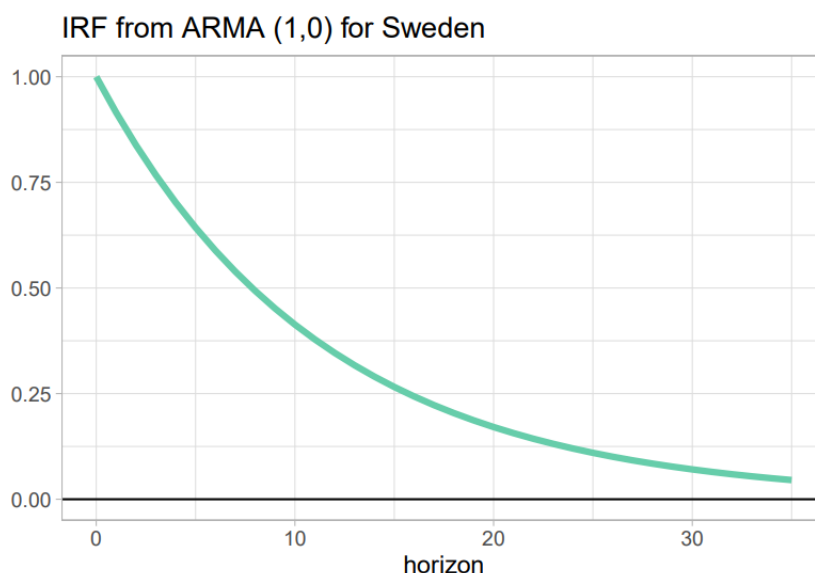


Rysunek 6: ACF dla modelu ARMA(1,0)

Powyższy wykres wskazuje, że występują jedynie autokorelacje dla okresu $t-1$, na co już wcześniej wskazał wzór oszacowanego modelu.

Funkcja reakcji na impuls

W kolejnym kroku zbadano jak nasza zmienna (inflacja) reaguje na szoki występujące dla innych zmiennych, w naszym wypadku dla inflacji z okresu poprzedniego. Wykorzystano do tego funkcję reakcji na impuls (IRF), która wygląda następująco:



Rysunek 7: Funkcja reakcji na impuls ARMA(1,0)

Z wykresu (Rys.7) wynika, że największy wpływ na zmienną mają szoki występujące w ostatnich okresach i ich wpływ na zmienną maleje wykładniczo. Im dawniejszy okres, tym mniejszy jest wpływ na zmienną w badanym okresie t . Wpływ zmiennej z okresu $t-1$ ma wpływ na zmienną z okresu t rzędu 90-95%, oznacza to, że jeśli wystąpił szok w okresie $t-1$ o 1 jednostkę, to w okresie t zmienna zmieni się o 0.9-0.95 jednostki.

Model VAR

Wstęp

Model VAR jest kolejnym sposobem na modelowanie szeregów czasowych, ten model również dobrze się sprawdza w celach prognostycznych i uwzględnia wzajemne powiązania między zmiennymi ekonomicznymi. Tego typu modele używane są do wielowymiarowych szeregów, nie posiadają podziału *a priori* na zmienne endogeniczne i egzogeniczne i podobnie do modelu ARMA charakteryzuje go ateoretyczność - jedynie wybór zbioru zmiennych do modelu podyktowany jest teorii. Ważną cechą modelu VAR jest stacjonarność, którą można zdefiniować w kategoriach wygasania wpływu szoku ϵ_t na wartość wektora y_t . W takim przypadku istnieje długookresowa wartość μ do której powraca proces y , a tempo powrotu do równowagi jest dane przez pierwiastki równania. Stacjonarny model VAR ma reprezentację nieskończonej wektorowej średniej ruchomej (VMA).

Najczęściej stosowaną metodą do estymacji modeli VAR jest MNK oddzielnie dla wszystkich równań. Stosowanie MNK jest uzasadnione bo zmienne objaśniające są z góry ustalone i tym samym niezależne względem składnika losowego ϵ_t (brak problemu endogeniczności zmiennych objaśniających).

Estymacja modelu i pierwiastki charakterystyczne

Do estymacji modelu VAR użyto dwóch zmiennych: inflacji w Szwecji oraz średniej inflacji w Europie (obie zmienne ściągnięto ze strony Eurostat) w okresie: styczeń 1997 – marzec 2021. Następnie na podstawie kryteriów informacyjnych oraz błędu predykcji wybrano okres opóźnienia - 2. Wyestymowany model VAR(2) prezentuje się następująco:

$$Y = 0,013pF_1 + 0,966pH_1 - 0,004pF_2 - 0,58pH_2 + 0,121$$

gdzie:

pH – inflacja w Szwecji

pF – inflacja w Europie

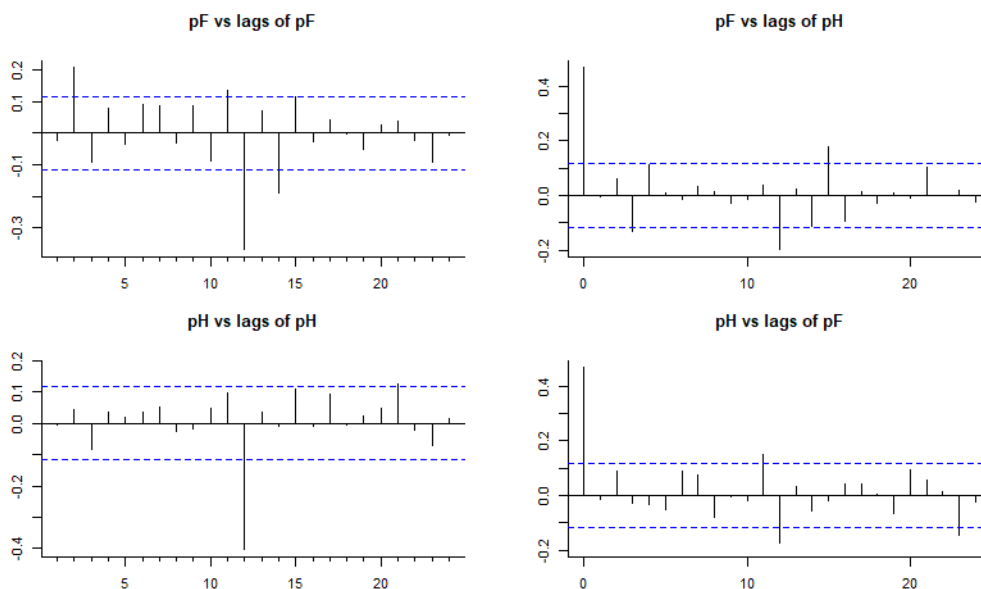
Jednak dla zmiennych pF_1 oraz pF_2 *p-value* uzyskało wartość wysoką, co wskazuje na nieistotność zmiennej. Z tego wynika, że na prognozowaną inflację w Szwecji mają wpływ jedynie inflacje w Szwecji z okresów $t-1$ oraz $t-2$. Skorygowane R^2 dla modelu wyszło równe 84,2% a pierwiastki charakterystyczne mają kolejno wartość: **0.9572, 0.9078, 0.08224, 0.02861**. Wszystkie pierwiastki są poniżej 1, co oznacza, że szereg jest stacjonarny tak samo, jak w przypadku skonstruowanego wcześniej modelu ARMA.

Dla tak zbudowanego modelu przeprowadzono test Ljunga-Boxa w celu sprawdzenia autokorelacji reszt. Test ten ma następujące hipotezy:

H0: Rozkład danych jest niezależny

H1: Dane wykazują autokorelację

Dla tak skonstruowanego testu wynik *p-value* jest równy około 1,3%, co mówi o odrzuceniu hipotezy zerowej i przyjęciu alternatywnej. Oznacza to, że występują autokorelacje w zbiorze danych. Autokorelacja dla opóźnień prezentuje się następująco:



Rysunek 8: Model VAR autokorelacja

Z powyższych wykresów (Rys. 8) widać, że autokorelacja dla zmiennej pH (Inflacja w Szwecji) występuje dla okresu $t-1$ (12 miesięcy wstecz), również zmienna pH jest skorelowana z inflacją w Europie dla okresów $t-1$ oraz $t-2$, jednak należy zwrócić uwagę, że jest to korelacja znacznie mniejsza.

Następnie dokonano testu przyczynowości Grangera, aby sprawdzić czy jeden szereg jest przydatny do prognozowania innego szeregu. Hipoteza zerowa w tym teście mówi o braku przyczynowości. Wartość p-value dla tego testu jest równa ponad 92%, co stanowi o przyjęciu hipotezy zerowej. Wynika z tego, że inflacja w Europie nie wpływa na przewidywane wartości inflacji w Szwecji, co potwierdziło wcześniejsze podejrzenia przy estymowaniu modelu VAR(2) – nieistotność opóźnionych zmiennych pF.

Funkcja reakcji na impuls

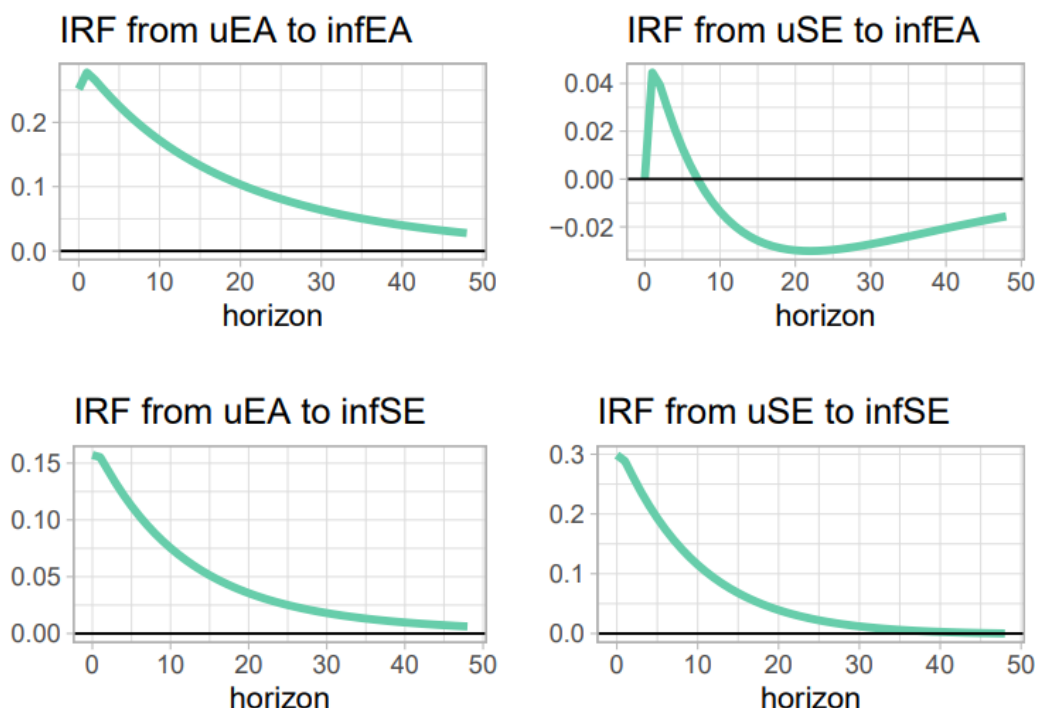
W celu przeprowadzenia dalszych badań dokonano dekompozycji Cholesky'ego dla badanego szeregu. Stworzono model SVAR, dla którego wyestymowane wartości są następujące:

	pF	pH
pF	0,25	0,00
pH	0,16	0,30

Rysunek 9: Model SVAR

Oznacza to, że zmiana inflacji w Europie o 1 jednostkę spowoduje zmianę inflacji w Europie w przyszłym okresie o 0,25 jednostki, a inflacji w Szwecji o 0,16 jednostki. Natomiast szok inflacyjny w Szwecji polegający na zmianie tej zmiennej o 1 jednostkę nie spowoduje żadnej zmiany w inflacji Europejskiej, ale za to zmieni inflację w Szwecji w okresie przyszłym o 0,3 jednostki.

Następnie zbudowano funkcję reakcji na impuls dla powyższej tabeli. Wyniki prezentują poniższe wykresy:



Rysunek 10: IRF dla SVAR

Gdzie:

uEA – zmiana inflacji w Europie o jednostkę (bez zmiany inflacji w Szwecji)

uSE – zmiana inflacji w Szwecji o jednostkę (bez zmiany inflacji w Europie)

infEA – zmiana inflacji w Europie w okresie przyszłym

infSE – zmiana inflacji w Szwecji w okresie przyszłym

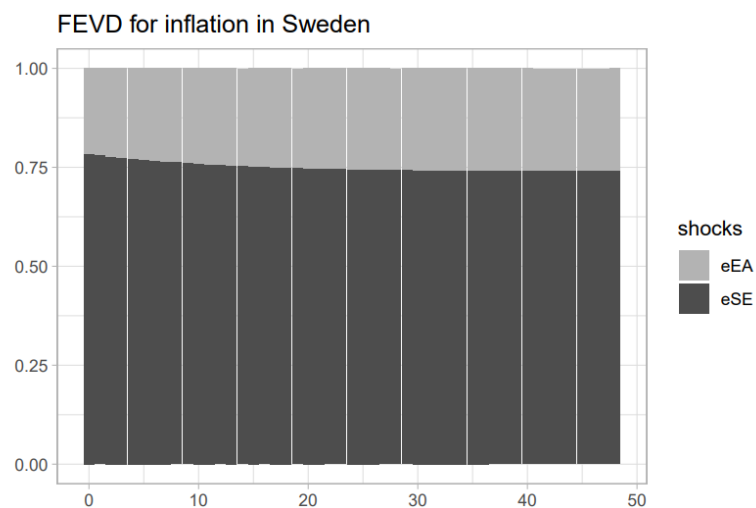
Jak widać na powyższych wykresach (Rys.10) zmiana inflacji w Europie o jednostkę powoduje zmiany inflacji w Europie oraz Szwecji, jednak funkcja reakcji na impuls jest malejąca i maleje wykładniczo wraz z kolejnymi okresami. Podobna sytuacja jest dla szoku inflacji w Szwecji mający wpływ na inflację w Szwecji, jednak dla szoku inflacyjnego w Szwecji oddziaływanie na inflację w Europie wygląda inaczej. Funkcja pik przyjmuje dla okresu 1, a potem drastycznie maleje tak, by przy okresie 24 znowu rosnąć i dążyć do 0.

FEVD

Po zbadaniu IRF sprawdzono dekompozycję wariancji budowy prognozy (FEVD). Oznacza to sprawdzenie jaki wpływ mają zmienne (inflacja w Europie oraz inflacja w Szwecji) na prognozowane wartości inflacji w Szwecji. Można to porównać do nadania wag zmiennym, gdzie wagi sumują się do 1, w zależności od okresu prognozy. Te wagi przedstawia poniższa tabela oraz wykres:

Horyzont	eEA	eSE
0	0,22	0,78
1	0,22	0,78
2	0,22	0,78
3	0,23	0,77
4	0,23	0,77
12	0,25	0,76
24	0,26	0,74
48	0,26	0,74

Rysunek 11: FEVD tabela




Rysunek 12: FEVD wykres

Jak widać na powyższych rysunkach (Rys. 11, Rys.12) inflacja w Szwecji ma znacznie większy wpływ na prognozowaną zmienną, w zależności od okresu jest to około 74-78% wpływu. Należy też zwrócić uwagę, że wagi nie zmieniają drastycznie swoich wartości wraz ze zmianą okresu – są one stałe.

Dekompozycja historyczna

Ostatnią wykonaną czynnością przed próbą prognozowania zmiennej jest dekompozycja historyczna. Pokazuje ona nie tyle jakie wagi wpływu mają zmienne na zmienną prognozową, ale jak one się rozkładają oraz z jakim znakiem (+/-) dla wartości historycznych. Poniższy wykres przedstawia tę dekompozycję (gdzie uEA – zmiana inflacji w Europie, uSE – zmiana inflacji w Szwecji):




Rysunek 13: Dekompozycja historyczna

Jak widać na powyższym wykresie (Rys. 13) dominuje zmiana inflacji w Szwecji, co już wcześniej pokazało FEVD. Należy też zwrócić uwagę, że w większości przypadków zmienne u_{EA} oraz u_{SE} mają zgodny znak, jednak nie zawsze. W niektórych momentach w historii zmiana inflacji w Europie miała przeciwny znak niż zmiana inflacji w Szwecji, np. w 2008 roku, inflacja w Europie ogólnie zmalała, a mimo to wpływ inflacyjny w Szwecji był dodatni.


Prognoza

Ostatnim krokiem w tym projekcie jest wykonanie prognozy dla zbudowanych modeli oraz porównać wyniki z jedną z najprostszych metod prognozowania szeregów czasowych – model chodzenia losowego (RW). Prognozę tych trzech modeli: ARMA(1,0), VAR(2) oraz RW na najbliższej trzy lata (tj. 2021-2023) przedstawiają poniższe wykresy:




Rysunek 14: Prognoza model ARMA(1,0)

Sequential forecast VAR (2)



Rysunek 15: Prognoza model VAR(2)

Sequential forecast RW



Rysunek 16: Prognoza model RW

Jak widać na powyższych wykresach (Rys.14-16) prognoza dla modeli ARMA oraz VAR są do siebie bardzo zbliżone, jednak model chodzenia losowego przewiduje wartości średnie liniowo, dlatego wykres prognozy znacząco różni się od pozostałych. W celu oceny, która prognoza jest „najlepsza” czyli najbardziej prawdopodobna przeprowadzono odpowiednie testy. Porównano prognozy według trzech testów. Pierwsze dwa oceniono na podstawie prognozy ex-post (60 miesięcy): średni błąd (ME) oraz pierwiastkowy błąd średniokwadratowy (RMSE), ostatnim jest test Diebolda-Mariano (DM). Należy zwrócić uwagę, że test DM porównuje dwie prognozy – do porównania wybrano prognozę z modelu ARMA oraz VAR. Poniższe tabele przedstawiają otrzymane wyniki dla kilku kolejnych miesięcznych okresów:

RMSE	1	2	3	6	9	12
RW	0,359	0,491	0,569	0,592	0,774	0,817
ARMA	0,352	0,472	0,538	0,569	0,708	0,756
VAR	0,354	0,47	0,534	0,549	0,674	0,718

Rysunek 17: Błąd prognozy RMSE

ME	1	2	3	6	9	12
RW	0,017	0,029	0,022	-0,011	-0,021	-0,1
ARMA	0,034	0,062	0,074	0,102	0,152	0,157
VAR	0,027	0,05	0,055	0,064	0,096	0,087

Rysunek 18: Błąd prognozy ME

DM	1	2	3	6	9	12
ARIMA	0,201	0,239	0,191	0,556	0,442	0,654
VAR	0,44	0,186	0,103	0,133	0,201	0,373

Rysunek 19: Błąd prognozy test DM

Dla wszystkich testów pożądany wynik jest jak najmniejszy. Dla błędu RMSE najmniejsze wartości otrzymała prognoza modelu RW, dla błędu ME model ARMA a dla testu DM model ARMA dla krótkich okresów, ale długoterminowo model VAR.

Porównano również wartości otrzymanych prognoz na najbliższe dwa i trzy lata z przewidywaniami opublikowanymi przez Europejską Komisję. Te wyniki przedstawia poniższa tabela:

Prognoza	ARMA (1,0)	VAR (2)	EUC
2021	1,71	1,68	1,3
2022	1,55	1,5	1,1
2023	1,5	1,46	

Rysunek 20: Porównanie prognoz

Jak widać w powyższej tabeli (Rys.20) model VAR ma znacznie bliższe wartości prognozy do zmiennej EUC (prognoza Europejskiej Komisji) niż model ARMA.

Ostatecznie uznano prognozę modelu VAR za najlepszą, ponieważ według testu DM otrzymała najlepsze wartości, a w RMSE wartości błędu mniejsze niż otrzymane w modelu ARMA i jest najbliższy przewidywanej wartości przez Komisję Europejską.

Spis Rysunków

Rysunek 1: Poziom inflacji w Szwecji (1997-2020)	1
Rysunek 2: Autokorelacja zmiennej	2
Rysunek 3: Porównanie wyników testów na stacjonarność szeregu	2
Rysunek 4: Kryterium AIC.....	3
Rysunek 5: Kryterium BIC.....	3
Rysunek 6: ACF dla modelu ARMA(1,0)	4
Rysunek 7: Funkcja reakcji na impuls ARMA(1,0)	4
Rysunek 8: Model VAR autokorelacja	6
Rysunek 9: Model SVAR	6
Rysunek 10: IRF dla SVAR	7
Rysunek 11: FEVD tabela	8
Rysunek 12: FEVD wykres	8
Rysunek 13: Dekompozycja historyczna	9
Rysunek 14: Prognoza model ARMA(1,0)	9
Rysunek 15: Prognoza model VAR(2)	10
Rysunek 16: Prognoza model RW	10
Rysunek 17: Błąd prognozy RMSE	11
Rysunek 18: Błąd prognozy ME	11
Rysunek 19: Błąd prognozy test DM	11
Rysunek 20: Porównanie prognoz	11

Spis treści

Opis zmiennej	1
Wstęp.....	1
Autokorelacja i test UR	1
Model ARMA	3
Wstęp.....	3
Kryteria informacyjne	3
Szacowanie modelu ARMA (1,0) i pierwiastki charakterystyczne	3
Funkcja reakcji na impuls	4
Model VAR	5
Wstęp.....	5
Estymacja modelu i pierwiastki charakterystyczne	5
Funkcja reakcji na impuls	6
FEVD.....	7
Dekompozycja historyczna	8
Prognoza	9
Spis Rysunków	12